

VISENET 2.0: Hệ thống cảnh báo giao dịch thông minh theo thời gian thực

Trần Nam Hải, Nguyễn Vũ Trung Kiên, Phạm Tiến Dũng
Trường Công nghệ Thông tin và Truyền thông, Đại học Bách khoa Hà Nội, Việt Nam
Email: {trannamhai.5d, ngkienn89, tiendungcbh1801}@gmail.com

Đội thi HD4K - Vòng 03 cuộc thi Data Science Talent Competition 2025

Tóm tắt nội dung—Trong bối cảnh thị trường chứng khoán biến động liên tục, việc cập nhật và phản ứng với tín hiệu giao dịch theo thời gian thực đóng vai trò quyết định đến hiệu quả đầu tư. Kế thừa kết quả từ vòng 02, chúng tôi tiếp tục sử dụng tập 30 cổ phiếu đã được chọn lọc bằng thiết kế thực nghiệm hỗn hợp, từ đó mở rộng sang xây dựng hệ thống cảnh báo giao dịch realtime. Cốt lõi của hệ thống là mô hình ensemble kết hợp ba thuật toán actor-critic (PPO, A2C, TD3), được huấn luyện trên dữ liệu lịch sử để học logic ra quyết định mua/bán tối ưu. Khi có dữ liệu mới về các cổ phiếu từ FiinQuant, hệ thống tự động cập nhật trạng thái thị trường, đánh giá lại danh mục và phát hiện tín hiệu mua mới, bán chốt lời hoặc cảnh báo rủi ro. Để tăng tính minh bạch và tiện lợi, chúng tôi xây dựng giao diện web trực quan hóa dữ liệu, đồng thời tích hợp chức năng gửi cảnh báo tức thì qua Email/Telegram theo tùy chọn người dùng. Ngoài ra, logic cảnh báo được thiết kế để phản biện các tình huống thị trường bất ngờ, đảm bảo tính linh hoạt trong điều chỉnh chiến lược. Kết quả thực nghiệm cho thấy mô hình ensemble đưa ra các tín hiệu cảnh báo với độ chính xác cao nhờ được huấn luyện toàn diện trên dữ liệu lịch sử, trong khi hệ thống cảnh báo realtime vận hành ổn định, lưu trữ tốt và truyền tải kịp thời đến người dùng. Nhờ vậy, nhà đầu tư có thể nhận diện sớm cơ hội giao dịch, quản trị rủi ro tốt hơn và ra quyết định linh hoạt hơn trong giờ giao dịch thực tế. Mã nguồn khả dụng tại: <https://github.com/CryAndRRich/visenet>.

Từ khoá—Tín hiệu giao dịch realtime, Hệ thống cảnh báo tự động, Dashboard theo dõi, Chiến lược giao dịch ensemble, Thuật toán actor-critic, Thị trường chứng khoán Việt Nam

I. GIỚI THIỆU

Thị trường chứng khoán Việt Nam đang ngày càng sôi động, với biến động giá liên tục trong ngày và nhu cầu cấp thiết về các hệ thống có khả năng gửi cảnh báo đầu tư theo thời gian thực. Các phương pháp phân tích truyền thống dựa trên dữ liệu cuối ngày (end-of-day - EOD) thường chỉ dừng lại ở việc tổng hợp báo cáo hoặc tính toán thủ công, khiến tín hiệu giao dịch không được cập nhật kịp thời và thiếu tính hệ thống. Trong bối cảnh thị trường biến động nhanh, nhà đầu tư cần một cơ chế tự động xử lý dữ liệu EOD ngay khi có thông tin, từ đó đưa ra tín hiệu mua/bán hoặc cảnh báo rủi ro trước phiên giao dịch tiếp theo.

Cùng với đó, việc dữ liệu realtime và các công cụ như FiinQuant trở nên dễ tiếp cận đã mở ra khả năng thiết kế các hệ thống cảnh báo giao dịch tức thời. Tuy nhiên, việc xây dựng hệ thống này đặt ra nhiều thách thức: vừa phải đảm bảo tính chính xác của tín hiệu, vừa phải vận hành ổn định trong suốt giờ giao dịch, đồng thời minh bạch trong việc giải thích logic chiến lược.

Trong vòng 03 của **Data Science Talent Competition 2025**, thử thách đặt ra bao gồm:

- Sử dụng dữ liệu realtime để liên tục cập nhật và đánh giá tín hiệu mua/bán.
- Xây dựng hệ thống cảnh báo có khả năng phát hiện tín hiệu “mua mới”, “bán chốt lời” và “cảnh báo rủi ro”.
- Tích hợp cảnh báo đến người dùng qua email, Telegram hoặc dashboard trực quan, đồng thời đảm bảo giải thích logic chiến lược rõ ràng và khả năng thích ứng trước tình huống bất ngờ.

Để giải quyết bài toán này, chúng tôi kế thừa tập 30 cổ phiếu đã được lựa chọn từ vòng 02 bằng phương pháp thiết kế thực nghiệm hỗn hợp (mixture experimental design) [1] [2], cùng với mô hình **ensemble deep reinforcement learning** (PPO, A2C, TD3) đã được huấn luyện sẵn trên dữ liệu lịch sử. Ở vòng 03 của cuộc thi, định hướng chính của chúng tôi bao gồm:


- Tập trung làm rõ logic chiến lược và cách mô hình đưa ra quyết định mua/bán.
- Phát triển **hệ thống cảnh báo giao dịch thời gian thực** nhằm tự động phát hiện và gửi tín hiệu đến người dùng.

Hệ thống được triển khai với giao diện web từ thư viện **Streamlit**, cho phép hiển thị trạng thái cổ phiếu và cảnh báo (mua mới, bán chốt lời, cảnh báo rủi ro), đồng thời hỗ trợ gửi thông báo tức thì qua Email hoặc Telegram mà người dùng đăng ký. Kết quả thực nghiệm cho thấy mô hình ensemble đưa ra tín hiệu cảnh báo chính xác nhờ quá trình huấn luyện toàn diện, trong khi hệ thống vận hành ổn định, lưu trữ tốt và truyền tải thông tin kịp thời đến người dùng. Điều này không chỉ giúp nhà đầu tư nhận diện sớm cơ hội sinh lời mà còn nâng cao khả năng quản trị rủi ro và thích ứng linh hoạt với thị trường.

II. DỮ LIỆU VÀ MÔI TRƯỜNG GIAO DỊCH

A. Dữ liệu

Trước khi sử dụng **hệ thống cảnh báo giao dịch**, người dùng đã có sẵn một tập hợp cổ phiếu tiềm năng trên các sàn chứng khoán HOSE, HNX, UPCOM phù hợp với bản thân được lựa chọn từ **VISENET** (Xem thêm tại Hình 1). Trong quá trình sử dụng, người dùng có thể nhập thêm mã cổ phiếu quan tâm hoặc tải lên một tệp chứa danh sách mã. Từ danh sách này, hệ thống cảnh báo giao dịch sẽ truy xuất dữ liệu từ thư viện **FiinQuant**, cụ thể là các module EOD.



Hình 1. Sơ đồ khung mô hình chọn lọc cổ phiếu bằng phương pháp chấm điểm có trọng số

Sau khi dữ liệu được thu thập, hệ thống tiến hành tiền xử lý và tính toán các chỉ báo kỹ thuật cần thiết để làm đầu vào cho mô hình dự báo. Quá trình này bao gồm:

- **Tự động cập nhật dữ liệu:** Dữ liệu giá được lưu trữ dưới dạng tệp .csv và cập nhật định kỳ hằng ngày. Nhờ đó, hệ thống có thể hoạt động liên tục mà không cần can thiệp thủ công.
- **Tính toán chỉ báo kỹ thuật:** Các chỉ báo như RSI, MACD, trung bình động (MA), v.v. được tính toán từ dữ liệu giá và khối lượng, cung cấp thông tin đầu vào cho mô hình ensemble.
- **Lọc ngày giao dịch:** Các phiên không có hoạt động giao dịch (ngày nghỉ, ngày lễ, ngày thị trường đóng cửa) được tự động loại bỏ nhằm đảm bảo tính chính xác của dữ liệu.

Nhờ sự kết hợp giữa dữ liệu realtime từ FiinQuant và cơ chế cập nhật tự động, hệ thống cảnh báo giao dịch có thể trực quan hóa diễn biến giá cổ phiếu ngay trên web dashboard và phát hiện kịp thời các tín hiệu mua, bán hoặc cảnh báo rủi ro cho nhà đầu tư.

B. Môi trường giao dịch

Trước khi huấn luyện mô hình học sâu tăng cường, chúng tôi xây dựng một môi trường mô phỏng giao dịch thực tế, cho phép mô hình thực hiện tương tác và học hỏi. Trong giao dịch thực tế, nhiều yếu tố cần được xem xét, ví dụ như giá lịch sử, số cổ phiếu nắm giữ, và các chỉ báo kỹ thuật. Mô hình giao dịch sẽ thu thập các thông tin này thông qua môi trường, và thực hiện các hành động đã được định nghĩa. Chúng tôi sử dụng OpenAI Gym [3] [4] [5] [6] để triển khai môi trường và huấn luyện.

1) Môi trường cho nhiều cổ phiếu:

Chúng tôi sử dụng không gian hành động liên tục [7] để mô hình hóa giao dịch nhiều cổ phiếu, giả định rằng danh mục có tổng cộng 30 cổ phiếu.


a) Không gian trạng thái:

Trạng thái được biểu diễn bởi vector 181 chiều, bao gồm 7 thành phần thông tin $[b_t; p_t; h_t; M_t; R_t; C_t; X_t]$, mỗi thành phần được định nghĩa như sau:

- $b_t \in \mathbb{R}_+$: số dư tại thời điểm t .
- $p_t \in \mathbb{R}_+^{30}$: giá đóng cửa điều chỉnh của từng cổ phiếu.
- $h_t \in \mathbb{Z}_+^{30}$: số cổ phiếu đang nắm giữ.
- $M_t \in \mathbb{R}^{30}$: MACD (Moving Average Convergence Divergence), tính từ giá đóng cửa, là chỉ báo động lượng phổ biến [8].
- $R_t \in \mathbb{R}_+^{30}$: RSI (Relative Strength Index), tính từ giá đóng cửa, đo lường mức độ thay đổi gần đây. Nếu giá quanh đường hỗ trợ, cổ phiếu bị bán quá mức và có thể mua; nếu quanh đường kháng cự, cổ phiếu bị mua quá mức và có thể bán [8].
- $C_t \in \mathbb{R}_+^{30}$: CCI (Commodity Channel Index), tính từ giá cao, thấp và đóng cửa, so sánh giá hiện tại với giá trung bình để gợi ý mua hoặc bán [9].
- $X_t \in \mathbb{R}^{30}$: ADX (Average Directional Index), tính từ giá cao, thấp và đóng cửa, đo lường độ mạnh của xu hướng [10].

b) Không gian hành động:

Với một cổ phiếu, không gian hành động được định nghĩa là $\{-k, \dots, -1, 0, 1, \dots, k\}$, trong đó k và $-k$ lần lượt biểu diễn số lượng cổ phiếu tối đa có thể mua hoặc bán ($k \leq h_{\max}$, tham số giới hạn số lượng cổ phiếu trong mỗi hành động mua). Do đó, kích thước toàn bộ không gian hành động là $(2k + 1)^{30}$. Không gian này được chuẩn hóa về $[-1, 1]$ để phù hợp với các thuật toán học tăng cường như A2C và PPO, vốn định nghĩa chính sách trực tiếp trên phân phối Gaussian cần đối xứng và chuẩn hóa.



Hình 2. Tổng quan kỹ thuật load-on-demand

2) Quản lý bộ nhớ:

Quá trình huấn luyện mô hình có thể tiêu tốn rất nhiều bộ nhớ, đặc biệt khi số lượng cổ phiếu, loại dữ liệu, đặc trưng trong không gian trạng thái, cũng như số lớp và số lượng neuron trong mạng, hay kích thước batch tăng lên. Để giải quyết vấn đề này, chúng tôi áp dụng kỹ thuật **load-on-demand** nhằm tối ưu việc sử dụng bộ nhớ.

Như trong Hình 2, nguyên tắc của kỹ thuật này là không lưu trữ toàn bộ kết quả trung gian trong bộ nhớ, mà chỉ sinh ra chúng khi cần thiết. Nói cách khác, bộ nhớ chỉ được sử dụng tại thời điểm có yêu cầu truy xuất kết quả. Nhờ đó, mức sử dụng bộ nhớ được giảm đáng kể, đảm bảo hệ thống có thể xử lý tập dữ liệu lớn hơn và duy trì hiệu quả trong quá trình huấn luyện.

III. LOGIC CẢNH BÁO GIAO DỊCH

Khác với các phương pháp rule-based truyền thống vốn dựa trên những ngưỡng định sẵn (ví dụ RSI < 30 để mua, MACD giao cắt dương để xác nhận xu hướng), hệ thống của chúng tôi không áp dụng một tập luật cứng. Thay vào đó, logic cảnh báo được hình thành từ mô hình ensemble deep reinforcement learning, vốn đã được huấn luyện trên dữ liệu lịch sử để học mối quan hệ phức tạp và phi tuyến giữa các biến số thị trường. Nhờ vậy, tín hiệu giao dịch phản ánh không chỉ một chỉ báo riêng lẻ mà là **tổng thể hành vi thị trường đã được tối ưu hóa qua kinh nghiệm quá khứ**.

A. Quy trình ra quyết định cảnh báo

Quy trình cảnh báo của hệ thống gồm các bước sau:

- **Bước 1 - Tiếp nhận dữ liệu:** Hệ thống nhận dữ liệu EOD từ FiinQuant cho 30 cổ phiếu đã được lựa chọn từ vòng 2.
- **Bước 2 - Đánh giá trạng thái thị trường:** Mỗi cổ phiếu được biểu diễn dưới dạng một vector trạng thái bao gồm giá, biến động và các chỉ báo kỹ thuật liên quan.
- **Bước 3 - Ra quyết định sơ cấp:** Các mô hình DRL ánh xạ trạng thái thị trường sang xác suất hành động (mua, bán hoặc giữ).
- **Bước 4 - Tổng hợp ensemble:** Cơ chế ensemble tổng hợp kết quả từ nhiều mô hình để đưa ra quyết định cuối cùng, đảm bảo sự ổn định và độ tin cậy của cảnh báo.
- **Bước 5 - Phát tín hiệu cảnh báo:** Kết quả cuối cùng được phân loại thành ba loại tín hiệu: “mua mới”, “bán chốt lời” hoặc “cảnh báo rủi ro” và gửi tới người dùng.

Thay vì dựa vào một mô hình duy nhất, hệ thống của chúng tôi áp dụng cách tiếp cận ensemble, tức là tổng hợp kết quả từ nhiều mô hình DRL khác nhau. Cách tiếp cận này giúp hạn chế rủi ro từ sự sai lệch của từng mô hình riêng lẻ so với thị trường, đồng thời khai thác được những ưu điểm bổ sung lẫn nhau của các thuật toán PPO, A2C và TD3.

B. Cơ chế ra quyết định của các mô hình thành phần

Trong hệ thống cảnh báo, ba mô hình A2C, TD3 và PPO đảm nhiệm vai trò như những bộ não học hỏi trực tiếp từ dữ liệu lịch sử để đưa ra hành động. Thay vì dựa trên các ngưỡng kỹ thuật định trước như RSI hay MACD, các mô hình này sử dụng cơ chế *actor-critic*, trong đó:

- **Actor** là mạng chính sách $\pi_\theta(a|s)$, ánh xạ trạng thái thị trường s thành hành động a (mua, bán, hoặc giữ).
- **Critic** là mạng ước lượng giá trị (value function), đánh giá mức độ tốt/xấu của hành động trong một trạng thái cụ thể.

Quá trình huấn luyện diễn ra bằng cách cho mô hình tương tác với dữ liệu thị trường trong quá khứ, cập nhật cả actor và critic để tối đa hóa lợi nhuận kỳ vọng. Sự khác biệt then chốt giữa A2C, TD3 và PPO nằm ở cách chúng cập nhật chính sách và xử lý những hạn chế cổ hữu của policy gradient truyền thống.

1) Advantage Actor-Critic (A2C):

A2C [11] là một biến thể tiêu biểu của họ *actor-critic*, cập nhật chính sách dựa trên gradient chính sách có trọng số bởi hàm *advantage* $A(s, a)$:

$$\nabla_{\theta} J(\theta) = \mathbb{E} \left[\sum_{t=1}^T \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) A(s_t, a_t) \right]. \quad (1)$$

Ở đây mỗi phân tử có ý nghĩa:

- $\log \pi_{\theta}(a_t | s_t)$: log-xác suất của hành động a_t dưới chính sách hiện tại. Khi tăng log-prob của các hành động tốt, các hành động đó sẽ xuất hiện thường hơn.
- $A(s_t, a_t)$: *advantage*, đo mức **tốt hơn** hay **tệ hơn** của hành động a_t so với mức kỳ vọng tại trạng thái s_t .

Hai biểu diễn phổ biến cho $A(s_t, a_t)$ là:

$$A(s_t, a_t) = Q(s_t, a_t) - V(s_t), \quad (2)$$

hoặc (n-step/T D-estimate)

$$A(s_t, a_t) = r_t + \gamma V(s_{t+1}) - V(s_t), \quad (3)$$

trong đó r_t là phần thưởng thực tế thu được sau khi thực hiện a_t . Công thức trên thể hiện rõ bản chất logic của A2C: *actor* tăng xác suất các hành động từng đem lại lợi ích vượt trội trong quá khứ (những hành động có $A > 0$). Vì vậy, A2C có xu hướng ra quyết định dựa trên sự vượt trội tương đối: không phải vì một chỉ báo đơn lẻ đạt ngưỡng, mà vì hành động đó có lịch sử “thắng” so với hành vi trung bình tại trạng thái tương tự. Trong trading, điều này dẫn tới các đặc tính:

- **Ổn định:** tránh phản ứng quá mạnh trước nhiễu ngắn hạn vì A2C cập nhật dựa trên *advantage* chứ không chỉ *reward* tức thời.
- **Ưu tiên hành vi đã được “kiểm chứng”:** chỉ khi một hành động (ví dụ mua) có *advantage* dương liên tục ở nhiều trạng thái tương tự thì xác suất mua mới tăng cao.

2) Twin Delayed Deep Deterministic Policy Gradient (TD3):

TD3 [12] là phiên bản cải tiến của DDPG [13] cho không gian hành động liên tục; khác biệt logic quan trọng nhất là TD3 cố gắng loại bỏ *overestimation bias* trong ước lượng Q .

Mục tiêu critic (target) của TD3 được tính bằng:

$$y_i = r_i + \gamma \min_{j=1,2} Q'_{\theta'_j} \left(s_{i+1}, \mu'_{\theta'_j}(s_{i+1}) + \epsilon \right), \quad (4)$$

trong đó $\epsilon \sim \text{clip}(\mathcal{N}(0, \sigma), -c, c)$ là nhiễu bị chặn để thực hiện *target policy smoothing*. Hàm mất mát critic là:

$$L(\theta_{Q_j}) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{R}} \left[(y_i - Q(s, a | \theta_{Q_j}))^2 \right], \quad (5)$$

và actor được cập nhật (sau mỗi d lần cập nhật critic) theo gradient:

$$\nabla_{\theta_{\mu}} J(\theta_{\mu}) \approx \mathbb{E}_{s \sim \mathcal{R}} \left[\nabla_a Q(s, a | \theta_{Q_1}) \Big|_{a=\mu(s)} \nabla_{\theta_{\mu}} \mu(s | \theta_{\mu}) \right]. \quad (6)$$

Cuối cùng tham số mục tiêu cập nhật bằng *Polyak averaging*:

$$\theta' \leftarrow \tau \theta + (1 - \tau) \theta', \quad \tau \ll 1. \quad (7)$$

Các thành phần trên tạo nên logic ra quyết định đặc trưng của TD3, cụ thể:

- **Min over two critics:** khi lấy $\min(Q'_1, Q'_2)$, TD3 thường chọn mục tiêu một cách "bảo thủ": Chỉ khi cả hai critic đồng ý giá trị cao thì hành động mới được coi là "có giá trị", giúp giảm khả năng tạo ra tín hiệu mua giả do ước lượng nhiễu thông.
- **Policy smoothing** (ϵ): làm mượt giá trị mục tiêu theo không gian hành động, nên actor không học những đỉnh nhọn trong Q mà có xu hướng chọn hành động ổn định trên một vùng lân cận, dẫn tới quyết định ít dao động.
- **Delayed update:** actor chỉ cập nhật khi critic đã đủ ổn định, tránh actor phản ứng theo noise tạm thời.

Trong trading, chỉ khi model thực sự "tự tin" (hai critic đồng ý và mục tiêu mượt) thì TD3 sẽ khuyến nghị mua/bán mạnh, còn không thì sẽ im lặng/giữ.

3) Proximal Policy Optimization (PPO):

PPO [14] là phương pháp on-policy kiểm soát chặt bước cập nhật chính sách bằng cơ chế clipping. Định nghĩa tỉ lệ xác suất:

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}. \quad (8)$$

Hàm mục tiêu dạng clipped là:

$$J^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right], \quad (9)$$

với $\hat{A}_t$ là estimate của advantage (thường dùng GAE để giảm phương sai và điều chỉnh bias-variance). Clipping cho phép PPO chấp nhận các cập nhật làm chính sách tốt hơn nhưng không cho phép thay đổi quá mạnh trong một bước:

- Nếu $\hat{A}_t > 0$ nhưng $r_t(\theta)$ vượt ngưỡng $1 + \epsilon$, tác động được giới hạn, PPO tránh policy "vội vã" đẩy xác suất hành động lên quá cao chỉ vì một vài quan sát bất thường.
- Nếu $\hat{A}_t < 0$ và $r_t(\theta)$ nhỏ hơn $1 - \epsilon$, giảm xác suất cũng bị giới hạn, PPO tránh policy thay đổi quá nhanh theo những tín hiệu xấu cục bộ.

Trong trading, PPO cho ra các quyết định **cân bằng**: model thích ứng liên tục nhưng hạn chế việc phản ứng thái quá trước nhiễu, vì vậy tín hiệu thay đổi mượt và ổn định hơn so với policy gradient mỏng manh.

4) Lợi thế của mô hình ensemble:

Trong khi A2C nhấn mạnh sự ổn định nhờ đo lường lợi thế tương đối, thì TD3 đưa ra quyết định dứt khoát với cơ chế kiểm chứng kép từ hai critic, còn PPO duy trì sự cân bằng thông qua cập nhật chính sách trong phạm vi an toàn. Mỗi thuật toán phản ánh một logic khác nhau trong cách tiếp cận thị trường: thận trọng, quyết đoán, hoặc ưu tiên sự ổn định dài hạn.

Khi kết hợp trong một mô hình ensemble, các thuật toán này bổ sung điểm mạnh cho nhau. Dữ liệu lịch sử cho thấy thị trường có nhiều giai đoạn với đặc trưng khác nhau: có thời kỳ biến động nhẹ, có giai đoạn xu hướng rõ rệt, cũng có lúc biến động bất định. Trong từng bối cảnh, một thuật toán có thể tỏ ra vượt trội hơn hai thuật toán còn lại. Ensemble cho phép tận dụng sự đa dạng này, phân bổ trọng số linh hoạt giữa các thành phần, từ

đó tạo ra một chiến lược thống nhất nhưng vẫn thích nghi với thay đổi. Nhờ vậy, hệ thống cảnh báo giao dịch có thể đạt được sự ổn định, khả năng phản ứng nhanh, và hiệu quả cao hơn so với việc chỉ dựa vào một mô hình đơn lẻ.

C. Liên hệ với chiến lược giao dịch

Ngoài việc nhận diện các ngưỡng kỹ thuật, logic cảnh báo còn phản ánh một chiến lược giao dịch toàn diện. Cụ thể, mô hình ensemble được huấn luyện từ dữ liệu lịch sử đã học được những quy tắc ngầm nhất định để:

- Nhận diện cơ hội sinh lời khi trạng thái thị trường thuận lợi.
- Kích hoạt cảnh báo rủi ro khi thị trường xuất hiện tín hiệu bất lợi.
- Đưa ra khuyến nghị mua/bán phù hợp với bối cảnh, thay vì áp dụng cứng nhắc một quy tắc đơn lẻ.

Qua đó, cơ chế cảnh báo của hệ thống vừa đảm bảo **tính linh hoạt**, vừa duy trì **tính minh bạch**, cho phép nhà đầu tư hiểu rõ hơn logic đằng sau mỗi khuyến nghị.

IV. HỆ THỐNG CẢNH BÁO

Hệ thống cảnh báo được triển khai dưới dạng một nền tảng web kết hợp với cơ chế gửi thông báo tự động qua email. Cấu trúc này cho phép nhà đầu tư vừa quan sát dữ liệu và tín hiệu trực quan trên dashboard, vừa nhận được cảnh báo tức thì ngay cả khi không truy cập giao diện web. Quy trình sử dụng được thiết kế trực quan: Người dùng bắt đầu bằng bước đăng ký/dăng nhập, sau đó truy cập vào **dashboard chính** để theo dõi giá cổ phiếu, khối lượng và các chỉ báo kỹ thuật. Đồng thời, các quyết định mua/bán/giữ từ mô hình sẽ được hệ thống định dạng thành thông điệp cảnh báo và gửi trực tiếp đến email đã đăng ký, giúp đảm bảo thông tin luôn được truyền tải kịp thời.

A. Dashboard hiển thị tín hiệu giao dịch

Dashboard được phát triển trên nền tảng **Streamlit** [15], đóng vai trò là giao diện trực quan hóa dữ liệu và kết nối giữa mô hình dự báo với người dùng. Các thành phần chính bao gồm:

- **Xác thực và quản lý người dùng:** Cơ chế đăng nhập/dăng ký được tích hợp nhằm đảm bảo tính cá nhân hóa và an toàn trong sử dụng.
- **Lựa chọn cổ phiếu và phạm vi quan sát:** Người dùng có thể nhập trực tiếp mã cổ phiếu hoặc tải danh sách từ file. Dashboard cho phép lọc dữ liệu theo nhiều mốc thời gian (ngắn hạn hoặc dài hạn).
- **Biểu đồ và chỉ báo kỹ thuật:**
 - Với một cổ phiếu: Dashboard hiển thị biểu đồ nền kèm thanh khối, SMA/EMA và các chỉ báo phổ biến (RSI, MACD, CCI, ADX, turbulence).
 - Với nhiều cổ phiếu: Dashboard chuẩn hóa dữ liệu để so sánh hiệu suất, đồng thời làm nổi bật mã tăng trưởng mạnh nhất và yếu nhất trong danh mục.
- **Khả năng tương tác:** Các biểu đồ được xây dựng bằng thư viện Plotly và Altair, cho phép phóng to, xem chi tiết hoặc bật/tắt chỉ báo. Dữ liệu gốc cũng được trình bày dưới dạng bảng để tiện đối chiếu.



Hình 3. Giao diện chính của dashboard hiển thị dữ liệu và tín hiệu giao dịch

- **Tích hợp tín hiệu từ mô hình:** Kết quả dự báo từ mô hình ensemble được hiển thị song song với dữ liệu giá và chỉ báo, cung cấp cho người dùng bối cảnh đầy đủ trước khi ra quyết định.
- **Lịch sử thông báo:** Ngay trong giao diện chính, người dùng có thể theo dõi mục “Lịch sử thông báo”. Khi bấm vào, hệ thống sẽ hiển thị chi tiết các cảnh báo giao dịch đã phát sinh, giúp nhà đầu tư dễ dàng rà soát và đối chiếu lại các tín hiệu trong quá khứ.

Nhờ sự kết hợp giữa dữ liệu giá, chỉ báo kỹ thuật và tín hiệu mô hình, dashboard mang lại cho nhà đầu tư một công cụ theo dõi và phân tích toàn diện, thay thế cho việc chỉ dựa vào phân tích thủ công hoặc tín hiệu rời rạc.

B. Hệ thống cảnh báo thời gian thực


Để đáp ứng yêu cầu cập nhật tức thì, hệ thống tận dụng dữ liệu realtime từ thư viện **FiinQuant**. Thông qua hàm `Trading_Data_Stream`, người dùng có thể đăng ký danh sách cổ phiếu quan tâm (tickers); mỗi khi có dữ liệu mới, hàm callback sẽ tự động kích hoạt để xử lý và cập nhật. Cơ chế này cho phép hệ thống phát hiện biến động trong phiên, thay vì chờ dữ liệu cuối ngày (EOD).

Các hành động được mô hình ensemble sinh ra (mua, bán, giữ) được chuyển đổi thành thông điệp cảnh báo dễ hiểu. Email cảnh báo được hệ thống gửi tự động có định dạng ngắn gọn, bao gồm danh sách các khuyến nghị tại cùng một thời điểm. Thông điệp trong email nêu rõ hành động, khối lượng và mã cổ phiếu, ví dụ: “*Gợi ý: Mua 100.0 cổ phiếu VNM*” hoặc “*Gợi ý: Bán 50.0 cổ phiếu FPT*”. Những cảnh báo này hiển thị trực tiếp trên dashboard, đồng thời được gửi đến email đã đăng ký của người dùng. Việc gửi email được hiện thực bằng Python thông qua thư viện `smtplib`, cho phép hệ thống tự động định dạng thông điệp và truyền tải qua máy chủ SMTP (ví dụ Gmail).


Nhờ tích hợp đa kênh, người dùng có thể vừa quan sát diễn biến thị trường trên giao diện web, vừa nhận thông báo tức thì mà không cần liên tục theo dõi dashboard. Cơ chế này nâng cao tính chủ động và giảm thiểu khả năng bỏ lỡ tín hiệu trong bối cảnh thị trường biến động nhanh chóng.

V. KẾT QUẢ THỰC NGHIỆM

Với 30 mã cổ phiếu được chọn từ trước, chúng tôi chia dữ liệu lịch sử trong giai đoạn 2018–2025 thành hai giai đoạn chính: giai đoạn *in-sample* dùng cho huấn luyện (09/10/2018–04/04/2024) và giai đoạn *out-of-sample* dùng cho kiểm thử (05/04/2024–14/07/2025). Cụ thể, mô hình ensemble bắt đầu với giá trị tài khoản 1,000,000 vào ngày 05/04/2024. Với giả định là người dùng **tiếp nhận và thực hiện các quyết định giao dịch tương ứng với cảnh báo**, đường giá trị tài khoản thể hiện những biến động đáng kể, đặc biệt trong nửa cuối năm 2024 khi có các pha suy giảm mạnh. Tuy nhiên, sau giai đoạn điều chỉnh, tài khoản dần hồi phục và bứt phá rõ rệt từ đầu năm 2025. Đến ngày 14/07/2025, giá trị tài khoản đạt khoảng 1,453,218, tương ứng với mức tăng trưởng 45,32% so với vốn ban đầu (code minh họa tại tệp notebook `visenet_run_model.ipynb`).



Hình 4. Phân chia dữ liệu lịch sử các mã cổ phiếu



Hình 5. Cumulative Return của VISENET với ba mô hình A2C, PPO, TD3, chiến lược phân bổ danh mục Min-Variance và chỉ số VNINDEX (Giá trị danh mục ban đầu là 1.000.000, trong giai đoạn từ 05/04/2024 đến 14/07/2025)

Bảng I
SO SÁNH HIỆU SUẤT ĐẦU TƯ

(05/04/2024-14/07/2025)	VISENET	A2C	PPO	TD3	Min-Variance	VNINDEX
Cumulative Return	45.32%	37.73%	4.97%	16.02%	3.32%	16.15%
Annual Return	34.98%	29.30%	3.97%	12.67%	2.66%	14.37%
Annual Volatility	28.17%	23.25%	23.39%	24.86%	8.10%	21.10%
Sharpe Ratio	1.20	1.22	0.28	0.60	0.36	0.74
Max Drawdown	-24.00%	-15.84%	-22.53%	-16.12%	-6.96%	-18.11%
Total Trade	4707	4549	4016	4644		
Win Rate	52.86%	48.09%	42.68%	50%	50.32%	52.67%

Để đánh giá toàn diện hiệu quả giao dịch của hệ thống, chúng tôi sử dụng 7 chỉ số chính:

- **Cumulative Return (Tỷ suất sinh lợi tích lũy):** đo lường tổng lợi nhuận thu được so với vốn ban đầu [16].
- **Annualized Return (Tỷ suất sinh lợi hàng năm):** lợi nhuận trung bình hình học mà mô hình đạt được hàng năm [16].
- **Annualized Volatility (Độ biến động hàng năm):** độ lệch chuẩn hàng năm của lợi nhuận danh mục [16].
- **Sharpe Ratio:** đo lường lợi nhuận điều chỉnh theo rủi ro, được tính bằng cách lấy lợi nhuận hàng năm trừ đi lãi suất phi rủi ro rồi chia cho độ biến động hàng năm [17].
- **Max Drawdown (Mức sụt giảm tối đa):** phần trăm thua lỗ lớn nhất trong giai đoạn giao dịch [18].
- **Total Trade (Tổng số lần giao dịch):** số lượng giao dịch được thực hiện trong toàn bộ giai đoạn.
- **Win Rate (Tỷ lệ giao dịch có lãi):** phần trăm ngày giao dịch có lợi nhuận dương so với tổng số ngày giao dịch [17].


Trong thực nghiệm, các chỉ số này không chỉ phản ánh hiệu suất đầu tư mà còn cho thấy chất lượng hệ thống cảnh báo, ví dụ như Win Rate 52.86% cho thấy phần lớn cảnh báo đưa ra dẫn đến giao dịch có lợi nhuận. Chính vì vậy, những chỉ số này vừa phản ánh độ hiệu quả của mô hình ensemble, vừa phản ánh sự hiệu

quả của logic và hệ thống cảnh báo.

A. So sánh VISENET với Benchmark

Dựa trên Bảng I và Hình 5, có thể thấy về điểm mạnh, VISENET đạt **lợi nhuận tích lũy 45.32%** và **lợi nhuận trung bình hàng năm 34.98%**, vượt trội so với các mô hình đơn lẻ. Tỷ lệ giao dịch có lãi của VISENET đạt **52.86%**, cao hơn rõ rệt so với hầu hết mô hình khác, cho thấy khả năng ra quyết định có lợi hơn theo thời gian. Về rủi ro điều chỉnh theo lợi nhuận, VISENET đạt **Sharpe ratio 1.20**, cao hơn nhiều so với PPO, TD3 và Min-Variance [19], chỉ thua nhẹ so với A2C (1.22), điều này cho thấy ensemble vẫn duy trì hiệu quả lợi nhuận trên mỗi đơn vị rủi ro ở mức cạnh tranh.

Tuy nhiên, VISENET lại có **độ biến động hàng năm cao (28.17%)** và **max drawdown sâu (-24.00%)**, lớn hơn so với một số mô hình đơn lẻ (ví dụ A2C, TD3) và đặc biệt so với chiến lược Min-Variance (8.10% volatility; max drawdown 6.96%). Điều này cho thấy VISENET đánh đổi mức biến động cao để thu được lợi nhuận lớn hơn, và hệ quả là chịu rủi ro sụt giảm sâu hơn trong các giai đoạn thị trường bất lợi. Thêm nữa, VISENET có tổng số giao dịch tương đối lớn (Total Trade = 4707), điều này có thể dẫn tới chi phí giao dịch và trượt giá cao hơn trong triển khai thực tế nếu không mô hình hóa chi phí đầy đủ.



Hình 6. Top 3 giai đoạn drawdown lớn nhất của VISENET trong giai đoạn out-of-sample

Tóm lại, VISENET thể hiện **ưu thế tổng thể** về lợi nhuận và tỷ lệ thắng, đồng thời duy trì Sharpe ratio cao, cho thấy hiệu quả của việc kết hợp (ensemble) các tác tử. Tuy nhiên, nhà đầu tư/triển khai thực tế cần cân nhắc và bù đắp nhược điểm về biến động, drawdown và turnover - ví dụ bằng các biện pháp quản trị rủi ro (kỹ thuật *position sizing* [20], giới hạn đòn bẩy [21], cơ chế cắt lỗ [22]), tối ưu trọng số ensemble theo điều kiện thị trường để đảm bảo hiệu suất duy trì ưu thế.

B. Đánh giá hiệu suất VISENET trong giai đoạn thị trường biến động mạnh

Quan sát Hình 6 cho thấy VISENET trải qua một giai đoạn drawdown đáng kể kéo dài từ tháng 3 đến tháng 5 năm 2025. Đây là giai đoạn thị trường xuất hiện nhiều biến động bất lợi, gây áp lực mạnh lên hầu hết các mô hình giao dịch.

Kết quả thực nghiệm cho thấy hệ thống cảnh báo của VISENET phát hiện kịp thời các tín hiệu suy giảm: số lượng cảnh báo bán tăng rõ rệt, tỷ lệ giao dịch thua lỗ có xu hướng tập trung trong chuỗi ngày giảm điểm. Điều này phản ánh rằng mô hình nhận diện được rủi ro, nhưng do đặc tính của ensemble ưu tiên bám sát xu hướng, tài khoản vẫn ghi nhận mức drawdown tối đa **-24.00%**.

Điểm đáng chú ý là ngay sau giai đoạn thị trường điều chỉnh, hệ thống cảnh báo nhanh chóng chuyển dịch từ tín hiệu phòng thủ sang tín hiệu mua, giúp tài khoản phục hồi và quay lại xu hướng tăng trưởng từ giữa năm 2025. Thực nghiệm cho thấy sự bứt phá này đóng góp trực tiếp vào mức **Cumulative Return 45.32%** cuối kỳ, chứng minh rằng hệ thống không chỉ có khả năng nhận diện rủi ro ngắn hạn mà còn thích ứng tốt với sự đảo chiều của thị trường.

Tóm lại, các kết quả thực nghiệm trong giai đoạn biến động mạnh cho thấy:

- Hệ thống cảnh báo hoạt động đúng chức năng khi liên tục phát đi tín hiệu phòng thủ trong giai đoạn suy giảm.

- Dù không loại bỏ hoàn toàn drawdown, VISENET vẫn đảm bảo khả năng phục hồi nhanh và bám sát xu thế hồi phục.
- Điều này minh chứng cho ưu thế của phương pháp ensemble trong việc duy trì hiệu quả đầu tư ổn định, ngay cả dưới tác động của cú sốc thị trường.

VI. KẾT LUẬN

Trong bài báo cáo này, chúng tôi đã thiết kế và triển khai một hệ thống cảnh báo giao dịch chứng khoán dựa trên mô hình học trọng số và chiến lược ensemble. Trọng tâm của bài báo cáo là làm rõ cơ chế sinh tín hiệu (mua, bán, giữ) và xây dựng thành một hệ thống cảnh báo thời gian thực, vận hành đa kênh. Dashboard trực quan cho phép nhà đầu tư quan sát dữ liệu giá, khối lượng và các chỉ báo kỹ thuật, đồng thời tích hợp thêm mục “Lịch sử thông báo” để truy vết toàn bộ tín hiệu đã phát sinh. Song song, cơ chế gửi cảnh báo qua email bảo đảm thông tin được truyền tải tức thì, ngay cả khi người dùng không theo dõi giao diện web.

Kết quả thử nghiệm cho thấy hệ thống cảnh báo thời gian thực đã cung cấp thông tin nhanh chóng và chính xác, góp phần nâng cao tính chủ động cho nhà đầu tư trong bối cảnh thị trường biến động liên tục. Trong tương lai, chúng tôi sẽ tiếp tục mở rộng bằng cách tích hợp thêm dữ liệu vĩ mô và tin tức tài chính, cải tiến cơ chế cá nhân hóa mức độ cảnh báo, đồng thời phát triển dashboard tổng hợp hỗ trợ quản lý phân bổ danh mục, giao dịch cổ phiếu và crypto. Những nâng cấp này nhằm tăng cường tính thích ứng và giá trị ứng dụng thực tiễn của hệ thống.

TÀI LIỆU THAM KHẢO

- [1] D.C. Montgomery, *Design and analysis of experiments*. Wiley, New York, 2012, pp. 611–622.
- [2] R.H. Myers and D.C. Montgomery, *Response surface methodology*. Wiley, New York, 2008.
- [3] Ashley Hill, Antonin Raffin, Maximilian Ernestus, Adam Gleave, Anssi Kanervisto, Rene Traore, Prafulla Dhariwal, Christopher Hesse, Oleg Klimov, Alex Nichol, Matthias Plappert, Alec Radford, John Schulman, Szymon Sidor, and Yuhuai Wu, “Stable baselines”, 2018.

- [4] Prafulla Dhariwal, Christopher Hesse, Oleg Klimov, Alex Nichol, Matthias Plappert, Alec Radford, John Schulman, Szymon Sidor, Yuhuai Wu, and Peter Zhokhov, "OpenAI baselines", 2017.
- [5] Greg Brockman, Vicki Cheung, Ludwig Pettersson, Jonas Schneider, John Schulman, Jie Tang, and Wojciech Zaremba, "OpenAI gym," 2016.
- [6] Mark Towers, Ariel Kwiatkowski, Jordan Terry, John U. Balis, Gianluca De Cola, Tristan Deleu, Manuel Goulão, Andreas Kallinteris, Markus Krimmel, Arjun KG, Rodrigo Perez-Vicente, Andrea Pierré, Sander Schulhoff, Jun Jet Tai, Hannah Tan, Omar G. Younis, "Gymnasium: A Standard Interface for Reinforcement Learning Environments", 2024 (arXiv:2407.17032).
- [7] Hongyang Yang, Xiao-Yang Liu, Shan Zhong, and Anwar Walid, "Deep reinforcement learning for automated stock trading: an ensemble strategy," 2020.
- [8] Terence Chong, Wing-Kam Ng, and Venus Liew, "Revisiting the performance of MACD and RSI oscillators," *Journal of Risk and Financial Management*, vol. 7, pp. 1–12, 03 2014.
- [9] Mansoor Maitah, Petr Prochazka, Michal Cermak, and Karel Sredl, "Commodity channel index: evaluation of trading rule of agricultural commodities," *International Journal of Economics and Financial Issues*, vol. 6, pp. 176–178, 03 2016.
- [10] Ikhlās Gurrib, "Performance of the average directional index as a market timing tool for the most actively traded USD based currency pairs," *Banks and Bank Systems*, vol. 13, pp. 58–70, 08 2018.
- [11] Volodymyr Mnih, Adrià Puigdomènech Badia, Mehdi Mirza, Alex Graves, Timothy P. Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu, "Asynchronous methods for deep reinforcement learning," *CoRR*, abs/1602.01783, 2016.
- [12] Scott Fujimoto, Herke van Hoof, and David Meger, "Addressing Function Approximation Error in Actor-Critic Methods," in *Proceedings of the 35th International Conference on Machine Learning*, PMLR 80, pp. 1587–1596, 2018.
- [13] Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, and Daan Wierstra, "Continuous control with deep reinforcement learning," *arXiv preprint arXiv:1509.02971*, 2015.
- [14] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov, "Proximal Policy Optimization Algorithms," *arXiv preprint arXiv:1707.06347*, 2017.
- [15] A. Sihombing and S. Sitanggang, "Design of a Stock Forecasting Dashboard using Python-Streamlit and FB Prophet with AI," *Formosa Journal of Science and Technology*, vol. 3, no. 4, pp. 561–570, 2024.
- [16] Z. Bodie, A. Kane, and A. J. Marcus, *Investments*, 10th ed., McGraw-Hill Education, 2014.
- [17] D. H. Bailey, J. Borwein, M. Lopez de Prado, and Q. J. Zhu, "Pseudo-Mathematics and Financial Charlatanism: The Effects of Backtest Overfitting on Out-of-Sample Performance," *Notices of the American Mathematical Society*, vol. 61, no. 5, pp. 458–471, 2014.
- [18] M. Magdon-Ismail, A. Atiya, A. Pratap, and Y. Abu-Mostafa, "On the Maximum Drawdown of a Brownian Motion," *Journal of Applied Probability*, vol. 41, no. 1, pp. 147–161, 2004.
- [19] H. Markowitz, *Portfolio Selection: Efficient Diversification of Investments*. Wiley, New York, 1959.
- [20] H. Scholz, "The influence of position sizing on the performance of technical trading rules," *Discussion Papers of the Chair of Statistics, Econometrics and Quantitative Methods*, No. 31, 2012.
- [21] N.-H. Chan and H. Ma, "A framework for stop-loss analysis on trading strategies," *The Journal of Trading*, vol. 10, no. 3, pp. 24–34, 2015.
- [22] R. Baviera and S. Baldi, "Optimal statistical arbitrage with stop-loss and leverage constraints," *arXiv preprint*, arXiv:1706.07021, 2017.